Universidade Estadual de Londrina
Centro de Ciências Exatas
Departamento de Computação
Ciência de Dados e Inteligência Artificial

**Disciplina Governança de TI e de Dados**

PROJETO

# ETAPA 2

## Governança e Qualidade dos Dados

*Governança aplicada ao ciclo de vida de uma solução de Ciência de Dados*

**Integrantes do grupo**

Alexandre da Silva Marchioli
Mateus Panunci Gonçalves

Londrina – PR
2026

## Objetivo da Etapa

Transformar a base pública escolhida na Etapa 1, a Pesquisa de Informações Básicas Municipais (MUNIC 2024), do IBGE, em um ativo de dados documentado e governado, avaliando sua origem, qualidade, significado, limitações e condições de utilização.

O recorte adotado nesta etapa compreende as planilhas Governança e Informática e comunicação do arquivo da MUNIC 2024, por concentrarem as variáveis necessárias ao Índice de Maturidade Digital Municipal (IMDM) proposto na Etapa 1.

## 1. Inventário dos dados

O quadro a seguir documenta a procedência e as condições de utilização da base empregada no projeto.

| Item | Descrição |
|---|---|
| Fonte | Pesquisa de Informações Básicas Municipais (MUNIC), edição 2024 |
| Responsável / provedor | Instituto Brasileiro de Geografia e Estatística (IBGE) |
| Formato | Arquivo Excel (.xlsx), multi-abas; recorte do projeto: abas “Governanca” e “Informática e comunicação” |
| Período de referência | Entre Agosto de 2024 e Fevereiro de 2025 |
| Data de divulgação | 31/10/2025 (Versão atualizada em 07/11/2025 utilizada) |
| Frequência de atualização | Anual. A pesquisa aplica um rodízio de temas entre as edições (como Habitação e Transportes, por exemplo), mantendo a investigação de Recursos Humanos com periodicidade anual. |
| Quantidade de registros | 5.570 municípios em cada aba (pesquisa censitária, cobertura integral) |
| Quantidade de atributos | Governança: 169 colunas · Informática e comunicação: 205 colunas |
| Principais atributos | São diversos indicadores (a maioria Sim/Não) sobre os seguintes escopos:<br><br>Informática e comunicação:<br>● Formas de atendimento à distância (MTIC011-018);<br>● Estrutura em TI (MTIC06, MTIC071-078);<br>● Programa ou ação de inclusão digital (MTIC19), ações implementadas (MTIC211-217);<br>● Acesso à internet para a população (MTIC22, MTIC23, MTIC24, MTIC241-244);<br>● Formas de participação do cidadão pela internet (MTIC251-255);<br>● Transparência nas informações da prefeitura e acessibilidade digital (MTIC271-29).<br>Governança:<br>● Legislação municipal que garantem o direito de acesso à informação (MGOV1; MGOV031-036);<br>● Conselho Municipal de Transparência ou similar (MGOV26);<br>● Lei Geral de Proteção de Dados Pessoais (LGPD), área/pessoa responsável por implementação, procedimentos de coleta e uso de |

| Item | Descrição |
|---|---|
| | dados pessoais, regulamentação municipal específica, etc (MGOV32-36) |
| Chave de identificação | Código do município (IBGE), acompanhado de UF, região, população e faixa populacional |
| Licença / condições de utilização | Informações de natureza pública. É permitido o uso e o compartilhamento (amparado pela Lei de Acesso à Informação e política de dados abertos), sendo exigido o respeito à integridade dos dados e a citação da fonte (IBGE), conforme os Termos de Uso do portal do IBGE. |

O arquivo foi baixado no dia 04/10/2026 por meio do link: https://www.ibge.gov.br/estatisticas/sociais/educacao/10586-pesquisa-de-informacoes-basicas-municipais.html (atualizada em 07/11/2025).

## 2. Dicionário de dados

As variáveis da MUNIC são identificadas por códigos (Mgov32, Mtic06), cujo significado consta na aba "Dicionário" do arquivo. Essa aba, no entanto, não é uma relação de campos: trata-se de um índice temático, com os códigos dispersos entre células de título e de subtítulo, sem informação de tipo, domínio ou qualidade. O dicionário apresentado nesta seção foi, portanto, construído pelo grupo em duas frentes: a extração automatizada dos significados declarados pelo IBGE e o perfilamento das 360 variáveis diretamente sobre as tabelas da camada bronze.

### 2.1 Estrutura e método de construção

Cada variável do dicionário é descrita por cinco atributos:

- **Campo:** o código da variável, conforme consta nas tabelas (em minúsculas, após a padronização aplicada na ingestão).
- **Significado:** a pergunta correspondente do questionário, extraída da aba "Dicionário" por expressão regular.
- **Tipo:** classificação inferida dos valores observados: binário (apenas "Sim"/"Não"), categórico (até vinte valores distintos) ou texto livre.
- **Domínio:** os valores efetivamente observados na base, e não os valores teoricamente admissíveis.
- **Qualidade:** os percentuais de não-resposta e de não aplicabilidade apurados na seção 3.

Composição do dicionário por tipo de variável:

| Tipo inferido | Governança | Informática e com. | Total |
|---|---|---|---|
| Binário (Sim / Não) | 144 | 188 | 332 |
| Categórico (até 20 valores) | 12 | 7 | 19 |
| Texto livre | 6 | 3 | 9 |
| Total de variáveis | 162 | 198 | 360 |

### 2.2 Divergências identificadas na documentação

A construção do dicionário expôs três inconsistências entre a documentação fornecida pelo IBGE e os dados efetivamente publicados. Todas foram mantidas no relatório por constituírem achados de qualidade documental, e não falhas de processamento.

#### a) Divergência de capitalização entre documentação e dados

A aba "Dicionário" registra os códigos em caixa alta (MGOV32, MTIC06), enquanto os cabeçalhos das abas de dados utilizam capitalização mista (Mgov32, Mtic06). A

padronização aplicada converte os nomes de coluna para minúsculas, de modo que a associação entre dicionário e dados exige normalização explícita da caixa.

**b) Variáveis presentes nos dados e ausentes do dicionário**

Sete variáveis existem nas abas de dados sem qualquer entrada correspondente no dicionário. Como todas são variáveis-filhas, condicionadas a uma pergunta anterior, seu significado foi reconstruído pelo grupo a partir do domínio observado e da relação com a variável-pai. As reconstruções estão registradas na tabela abaixo, com a respectiva evidência, e o dicionário final identifica a origem de cada definição.

| Variável | Significado atribuído pelo grupo | Evidência utilizada |
|---|---|---|
| Mtic11 | Endereço eletrônico (URL) da página da prefeitura na internet | Os 5492 valores distintos seguem o padrão www.{município}.{uf}.gov.br. A variável sucede Mtic10 (“A página da prefeitura na internet está”). |
| Mtic31 | Denominação da estrutura organizacional da área de comunicação | Valores observados correspondem a nomes de órgãos (“Assessoria de Comunicação”, “Gabinete do Prefeito”). Os 3047 registros não aplicáveis coincidem exatamente com os 3047 municípios que responderam “Não” em Mtic30. |
| Mtic331 | Denominação do cargo ou carreira específica de comunicação social | Valores correspondem a cargos (“Jornalista”, “Assessor de Imprensa”), condicionados à existência declarada em Mtic33. |
| Mtic2421 | Abrangência da conexão Wi-Fi na área urbana (parte ou toda) | Mtic242 = “Sim” em 1429 municípios. Mtic2421 assume “Parte” ou “Toda” em exatamente 1429 registros. |
| Mtic2431 | Abrangência da conexão Wi-Fi na área rural (parte ou toda) | Mtic243 = “Sim” em 496 municípios. Mtic2431 assume “Parte” ou “Toda” em exatamente 496 registros. |
| Mgov141 | Total de pessoal ocupado especificamente no controle interno (quantidade informada) | Domínio composto por valores numéricos. Sucede Mgov13 (“Existência de pessoal ocupado especificamente no controle interno”). |
| Mgov142 | Declaração de desconhecimento do total de pessoal ocupado no controle interno | Mgov13 = “Sim” em 5079 municípios. 4936 informaram quantidade em Mgov141 e 142 assinalaram Mgov142, totalizando 5078 registros. Em Tamarana/PR não foi informado em Mgov141e Mgov142, totalizando 5079 registros. |

**c) Códigos documentados sem coluna correspondente**

Cinco códigos constam do dicionário sem variável correspondente nas abas de dados. Registra-se um provável erro de redação por parte do IBGE: a entrada de Mtic30 descreve “Estrutura organizacional para a área de educação - existência”, embora a variável pertença à seção 2.10 (Comunicação) e seja seguida por um bloco dedicado à área de comunicação. A evidência está no encadeamento das variáveis: Mtic31, que registra a denominação da estrutura cuja existência Mtic30 descreve, contém respostas como “Assessoria de Comunicação”, como foi mostrado na tabela do item anterior.

Também, conforme demonstrado, 3047 municípios que responderam “Não” em Mtic30 são exatamente os 3047 sem aplicabilidade tanto em Mtic31 quanto em Mtic33. Adotou-se, então, a leitura que decorre dos dados e não a escrita no dicionário.

## 2.3 Dicionário das variáveis centrais do projeto

O dicionário completo das 360 variáveis acompanha esta entrega como artefato (seção 2.4). Reproduz-se abaixo o bloco de variáveis referentes à Lei Geral de Proteção de Dados Pessoais, que concentra a variável-alvo do projeto e os achados de qualidade mais relevantes discutidos na seção 3.

| Campo | Significado | Tipo | Domínio | Qualidade |
|---|---|---|---|---|
| Mgov32 | Área ou pessoa responsável por procedimentos e políticas para coleta, armazenamento e uso de dados pessoais ou pela implementação das diretrizes da LGPD - existência | Binário | Não \| Sim | 15,76% de não-resposta; sem registros não aplicáveis |
| Mgov33 | Área ou pessoa responsável pelo projeto de implementação da LGPD - localização | Categórico | 7 valores observados | 0,72% de não-resposta; 71,78% não aplicável (condicionada a Mgov32) |
| Mgov34 | Cursos sobre segurança da informação e proteção de dados nos últimos 24 meses para servidores municipais - disponibilização | Binário | Não \| Sim | 14,42% de não-resposta; sem registros não aplicáveis |
| Mgov35 | Canais de atendimento pela internet para os cidadãos enviarem mensagens sobre o uso de seus dados pessoais - disponibilização | Binário | Não \| Sim | 15,12% de não-resposta; sem registros não aplicáveis |
| Mgov36 | Regulamentação ou lei municipal específica sobre a LGPD que identifica papéis e responsabilidades - existência | Binário | Não \| Sim | 13,72% de não-resposta; sem registros não aplicáveis |

## 2.4 Artefatos gerados

A construção do dicionário é integralmente reprodutível a partir do notebook de perfilamento, que lê as tabelas da camada bronze e grava os resultados no catálogo.

- **Notebook:** *bronze_quality_profiling (pasta governance do workspace).*
- **Tabela:** *munic_catalog.gold.dq_column_profile* — perfil completo das 360 variáveis.
- **Arquivo:** *dicionario_esqueleto.csv*, no volume munic_catalog.bronze.csv_files/quality_outputs.

## 3. Qualidade dos dados

As seis dimensões a seguir foram verificadas sobre as tabelas da camada bronze, antes de qualquer tratamento. Essa escolha é deliberada: a camada silver converte os cinco códigos de ausência da MUNIC em um único valor nulo, operação adequada à modelagem, porém destrutiva para fins de diagnóstico, pois elimina a distinção entre o município que se recusou a responder e aquele a quem a pergunta sequer foi dirigida.

O conjunto analisado compreende 360 variáveis de indicadores distribuídas entre as duas abas, sendo 198 em "Informática e comunicação" e 162 em "Governança", observadas em 5570 municípios, o que totaliza 2.005.200 observações.

### 3.1 Completude

**Verificação.** Classificação de cada uma das 2.005.200 observações em seis classes mutuamente exclusivas: resposta válida, "não sabe informar", "não informou", "recusa", não aplicável (código "-") e nulo técnico. A distinção entre as classes é essencial, pois o código "-" indica que a pergunta não se aplicava ao município em razão dos filtros de salto do questionário, não constituindo falha de preenchimento.

**Evidência:**

| Classe | Observações | % do total | Natureza |
|---|---|---|---|
| Resposta válida | 1.493.935 | 74,50% | Informação efetivamente prestada |
| Não aplicável ("-") | 500.916 | 24,98% | Ausência estrutural (filtro de salto) |
| Não informou | 4.413 | 0,22% | Não-resposta |
| Não sabe informar | 3.416 | 0,17% | Não-resposta |
| Recusa | 2.520 | 0,13% | Não-resposta |
| Nulo técnico | 0 | 0,00% | Ausência não codificada |

**Interpretação:** Quase um quarto da base encontra-se vazia, mas praticamente toda essa ausência é estrutural: 24,98% das observações correspondem a perguntas que não se aplicavam ao respondente. A não-resposta propriamente dita soma 0,52%, e não há um único valor nulo técnico, indicativo de um instrumento de coleta bem controlado. A mediana da não-resposta por variável é de 0,34%, e apenas 5 das 360 variáveis superam 1%.

Essa concentração é o achado central da dimensão. As quatro variáveis com maior não-resposta de toda a base são exatamente as do bloco de LGPD:

| Variável | Conteúdo | Não-resposta | "Não sabe informar" |
|---|---|---|---|
| Mgov32 | Responsável pela implementação da LGPD | 15,76% | 857 municípios |
| Mgov35 | Canais para o cidadão sobre uso de dados pessoais | 15,12% | 821 municípios |
| Mgov34 | Cursos de segurança da informação para servidores | 14,42% | 782 municípios |

| Variável | Conteúdo | Não-resposta | "Não sabe informar" |
|---|---|---|---|
| Mgov36 | Lei municipal específica sobre a LGPD | 13,72% | 743 municípios |

As demais 356 variáveis permanecem abaixo de 4% de não-resposta. A variável central adotada no projeto, Mgov32, é, portanto, a de pior completude de toda a base, com 878 municípios sem informação utilizável, dos quais 857 declararam explicitamente não saber informar. Esse resultado não deve ser lido apenas como limitação do dado: a incapacidade da própria prefeitura de afirmar se existe alguém responsável pela LGPD é, em si, um indicador de baixa maturidade em governança de dados, em que esse projeto se propõe a mensurar.

### 3.2 Validade

**Verificação:** Comparação entre o domínio observado de cada variável e o domínio esperado segundo seu tipo, com identificação de variáveis sem nenhuma resposta válida, de domínio degenerado (valor único) ou majoritariamente não aplicáveis.

**Evidência:** Nenhuma variável apresentou valor fora do domínio esperado: as 332 variáveis binárias contêm exclusivamente "Sim", "Não" e códigos de ausência, e nenhuma variável ficou sem resposta válida ou com valor único. Foram identificadas 76 variáveis com mais de 50% de registros não aplicáveis, das quais 30 ultrapassam 90%. O caso mais extremo é o conjunto Mgov3111 a Mgov3119, com 99,03% de não aplicabilidade. Ao todo, 207 das 360 variáveis apresentam algum registro não aplicável.

**Interpretação:** A base é válida no sentido estrito: não há valores fora de domínio nem inconsistências de tipo. Os 76 achados não indicam erro, e sim que o questionário é fortemente hierarquizado: blocos inteiros de perguntas só são apresentados a municípios que responderam afirmativamente a uma pergunta anterior (relação de perguntas pai e perguntas filhas, como numa estrutura hierárquica). A consequência disso é que, para essas variáveis, a amostra efetiva não corresponde aos 5570 municípios, e qualquer estatística calculada sobre elas precisa declarar o denominador real (voltar na cadeia de indicadores). Mgov33 ilustra o ponto: com 71,78% de não aplicabilidade, descreve apenas os 1572 municípios que declararam possuir responsável pela LGPD.

### 3.3 Consistência

**Verificação:** Dois testes foram realizados. O primeiro compara, município a município, os descritores comuns às duas abas (unidade da federação, população, faixa populacional e região). O segundo mede a cobertura entre o dicionário e as colunas efetivamente presentes nos dados.

**Evidência:** Nos descritores, foram encontradas zero divergências nas quatro variáveis comparadas, e nenhum município consta de uma aba sem constar da outra. Na cobertura

documental, sete variáveis existem nos dados sem entrada no dicionário e cinco códigos do dicionário não possuem coluna correspondente, conforme detalhado na seção 2.2.

**Interpretação:** A consistência interna dos dados é integral. O resultado dos descritores tem efeito prático direto sobre o pipeline: a etapa de tratamento extrai os atributos municipais exclusivamente da aba "Informática e comunicação", pressupondo que a aba "Governança" os repete de forma idêntica. A verificação confirma a premissa. As inconsistências detectadas estão, dessa forma, na documentação, e não nos dados.

### 3.4 Unicidade

**Verificação:** Contagem de valores distintos da chave de identificação municipal em cada aba, comparada ao total de registros. O teste exige deduplicação: a simples seleção da coluna recontaria as linhas e a verificação resultaria aprovada por construção, independentemente da existência de duplicidades.

**Evidência:** Aba "Informática e comunicação": 5570 registros e 5570 códigos municipais distintos. Aba "Governança": 5570 registros e 5570 códigos distintos. Nenhum código aparece em apenas uma das abas.

**Interpretação:** A chave primária é única em ambas as abas e a cobertura corresponde à totalidade dos municípios brasileiros até o ano de 2024, não contando o novo município de Boa Esperança do Norte, o que faz sentido pelo ano-base ser 2024. A junção entre as duas abas pode ser realizada sem risco de inconsistência de registros.

### 3.5 Atualidade

**Verificação:** Leitura dos metadados de linhagem registrados na ingestão (endereço de origem, nome do arquivo, ano de referência e instante de carga) e cálculo da defasagem em relação à data de uso.

**Evidência:** Ano de referência: 2024. Arquivo de origem: Base_MUNIC_2024_20251107.xlsx, obtido do endereço oficial do IBGE. A versão utilizada corresponde à republicação de 7 de novembro de 2025, posterior à divulgação inicial de 31 de outubro de 2025. Ingestão foi realizada em 7 de outubro de 2026.

**Interpretação:** A defasagem entre o ano de referência e o uso é compatível com a periodicidade anual da pesquisa e não compromete a finalidade do projeto, que descreve a maturidade digital municipal em um corte transversal.

### 3.6 Acurácia

**Verificação:** As notas técnicas da MUNIC 2024 permitem uma verificação externa parcial: o IBGE declara que sete municípios recusaram responder à pesquisa e os nomeia, sendo eles Xapuri (AC), Colares e Vigia (PA), Buriti e Carolina (MA), Santa Cecília (SC) e Bagé (RS).

A base confirma exatamente esses sete, e as 2520 células com código "Recusa" correspondem a 7 municípios × 360 variáveis. Para o conteúdo das respostas, porém, não há fonte de confronto, e adotou-se a coerência interna como aproximação.

Se a pergunta B só é apresentada aos municípios que responderam "Sim" à pergunta A, então todo município com "Não" em A deve apresentar o código "-" em B. Para cada variável com participação relevante de registros não aplicáveis, buscou-se a variável que melhor explica esse padrão, medindo-se a cobertura (proporção dos registros não aplicáveis explicada pela variável-pai) e a precisão (proporção das respostas no valor de gatilho que resultam em não aplicabilidade).

**Evidência:** Foram avaliadas 171 variáveis com participação relevante de registros não aplicáveis. Em 133 delas a relação com a variável-pai foi confirmada, adotando-se como critério cobertura e precisão iguais ou superiores a 95%; em 90 desses casos ambas as medidas são exatamente 100%, caracterizando relação determinística: todo município que responde o gatilho apresenta o código "-" na variável-filha, e nenhum outro o apresenta. O gatilho é composto por mais de um valor em 35 dos pares. As 38 variáveis restantes foram classificadas como parciais. Exemplos:

| Filha | Pai | Valores de gatilho | Cobert. | Precisão | Relação identificada |
|---|---|---|---|---|---|
| Mtic23 | Mtic22 | Não | 100% | 100% | Caso simples: as condições do Wi-Fi só são perguntadas a quem disponibiliza acesso por conexão Wi-Fi (2877 não aplicáveis). |
| Mgov261c | Mgov26 | Não | 100% | 100% | Situação do Conselho de Transparência só é perguntada a quem declara possuí-lo (5432 não aplicáveis). |
| Mtic186 | Mtic176 | Sim | 100% | 100% | Gatilho invertido: os canais de acompanhamento só são perguntados a quem oferece algum canal de solicitação, e os 1279 municípios que assinalaram "nenhuma das alternativas" em Mtic176 são exatamente os 1279 não aplicáveis no bloco seguinte. |
| Mgov091 | Mgov09 | Não \| Sim, sem instrumento legal | 100% | 100% | Pai categórico com gatilho composto: o instrumento legal só é detalhado por quem possui estrutura de controle interno instituída por instrumento legal. Os 240 municípios sem estrutura somados aos 571 com estrutura sem instrumento legal reproduzem os 811 não aplicáveis. |
| Mgov33 | Mgov32 | Não \| Não sabe informar | 100% | 100% | Mesmo padrão aplicado à variável-alvo do projeto: a localização do responsável pela LGPD só é perguntada a quem afirma possuí-lo. Os 3141 municípios que responderam "Não" somados aos 857 que responderam "Não sabe informar" reproduzem exatamente os 3998 não aplicáveis. |
| Mtic321 | Mtic30 | Não | 99,6% | 100% | Relação parcial: a não aplicabilidade decorre de duas condições somadas, conforme detalhado a seguir. |

**Interpretação:** As 38 variáveis classificadas como parciais não representam incoerências: correspondem a casos em que a não aplicabilidade decorre de uma cadeia de mais de um nível, e o procedimento identifica apenas o pai imediato de maior poder explicativo.

O par Mtic321–Mtic30 ilustra esse comportamento e foi verificado em detalhe. A variável Mtic321 registra 3058 municípios não aplicáveis, enquanto Mtic30 ("existência de estrutura organizacional de comunicação") registra 3047 respostas negativas. Os onze municípios de

diferença declararam possuir a estrutura, informando inclusive sua denominação em Mtic31, mas responderam "Não sabe" em Mtic328 quanto ao vínculo do pessoal, o que também suprime as demais alternativas do bloco. Verificação equivalente aplica-se às demais variáveis parciais.

### 3.7 Síntese das verificações

| Dimensão | Verificação aplicada | Evidência obtida | Avaliação |
|---|---|---|---|
| Completude | Classificação das 2.005.200 observações em seis classes de preenchimento e ausência | 74,50% com resposta válida, 24,98% não aplicável, 0,52% de não-resposta e nenhum nulo técnico | Adequada no conjunto / crítica no bloco de LGPD |
| Validade | Aderência do domínio observado ao domínio esperado de cada variável | Nenhum valor fora de domínio. 76 variáveis com mais de 50% de registros não aplicáveis, 30 acima de 90% | Válida / exige declaração do denominador efetivo |
| Consistência | Comparação dos descritores municipais entre as abas e cobertura recíproca do dicionário | Zero divergências nos descritores e na cobertura de municípios. 7 variáveis sem entrada no dicionário e 5 códigos sem coluna | Íntegra nos dados / deficiente na documentação |
| Unicidade | Contagem de valores distintos da chave municipal em cada aba | 5.570 registros e 5.570 códigos distintos em ambas as abas | Chave primária íntegra |
| Atualidade | Defasagem entre ano de referência, versão do arquivo, ingestão e uso | Referência 2024: arquivo republicado em 07/11/2025. Ingestão em 07/10/2026 | Compatível com o uso / versão do arquivo rastreada |
| Acurácia | Coerência interna entre variáveis encadeadas por filtros de salto | 171 variáveis avaliadas: relação confirmada em 133 (cobertura e precisão ≥ 95%), das quais 90 determinísticas. As 38 restantes decorrem de cadeias de mais de um nível | Coerência interna confirmada / Recusas validadas contra a fonte |

### 3.8 Gráficos

A completude agregada examinada na seção 3.1 esconde um padrão que só se revela quando a não-resposta é medida sobre a variável-alvo isoladamente. As duas figuras a seguir demonstram que a ausência de resposta na MUNIC não é aleatória.

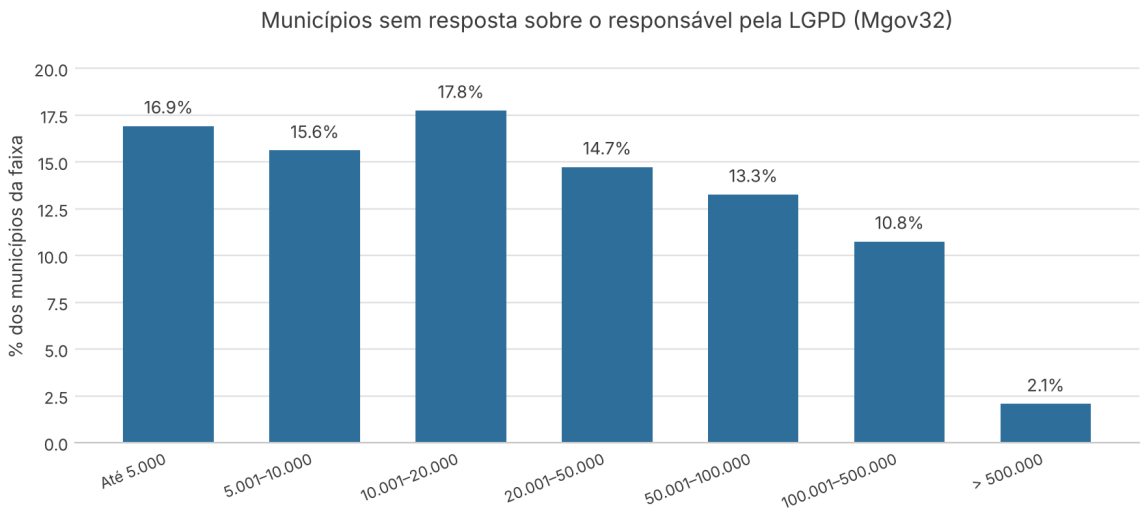



*Figura 1 – Municípios sem resposta válida em Mgov32, por faixa populacional*

Entre os municípios de até cinco mil habitantes, 16,93% não souberam informar se possuem área ou pessoa responsável pela LGPD. Entre os de mais de quinhentos mil, essa proporção cai para 2,08% (uma diferença de oito vezes). A relação não é estritamente monotônica, pois a faixa de 10.001 a 20.000 habitantes apresenta o pico de 17,76%, mas a tendência de queda a partir daí é consistente e os extremos são inequívocos.

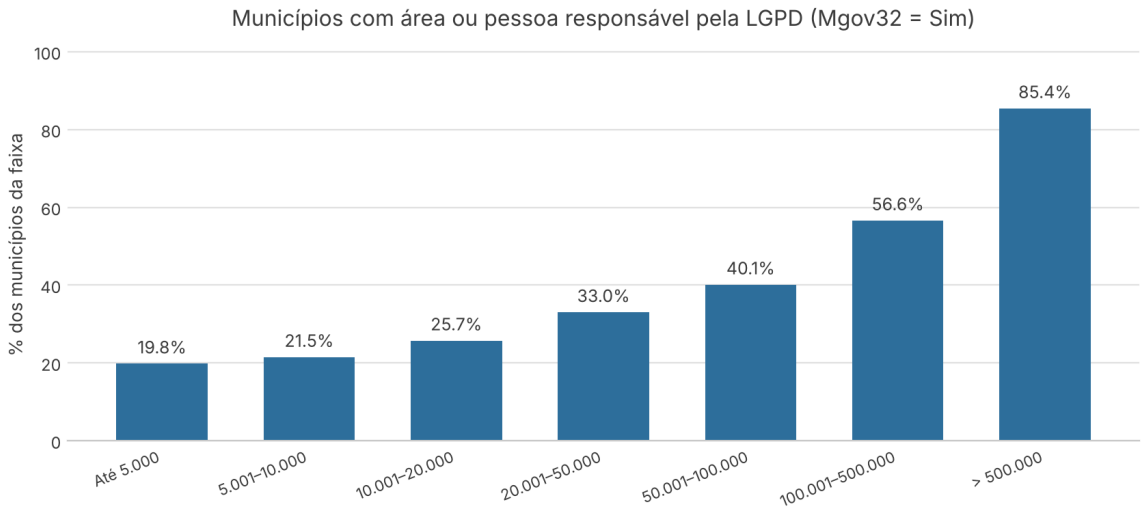



*Figura 2 – Municípios com área ou pessoa responsável pela LGPD (Mgov32 = "Sim"), por faixa populacional*

A segunda figura completa nosso argumento. A proporção de respostas afirmativas cresce de forma estritamente monotônica com o porte, de 19,80% na menor faixa a 85,42% na maior. Os dois gráficos lidos em conjunto mostram que os municípios menores simultaneamente respondem menos e respondem "Sim" menos.

### 3.9 Artefatos gerados

Todas as evidências desta seção são reprodutíveis pela execução do notebook de perfilamento sobre a camada bronze, e os resultados estão materializados no catálogo.

- *munic_catalog.gold.dq_column_profile*: perfil de qualidade das 360 variáveis.
- *munic_catalog.gold.dq_dimension_summary*: síntese das seis dimensões (tabela 3.7).
- *munic_catalog.gold.dq_nonresponse_by_size*: não-resposta e taxa de resposta afirmativa por faixa populacional (figuras 1 e 2).
- *munic_catalog.gold.dq_skiplogic_candidates*: pares pai-filha identificados na verificação de acurácia.

Os arquivos em formato CSV correspondentes encontram-se no volume *munic_catalog.bronze.csv_files*, na pasta *quality_outputs*.

## 4. Tratamento dos dados

As decisões de tratamento aplicadas à base estão registradas no quadro abaixo, de modo a assegurar a rastreabilidade entre o dado original e o dado utilizado na solução.

| Dado original | Problema identificado | Transformação aplicada | Justificativa |
|---|---|---|---|
| Nomes em CamelCase, com espaços e acentos | Dificuldade em Spark SQL e case sensitivity | Conversão para snake_case minúsculo | Padrão Spark/Python e previsibilidade |
| cod_munic como número inteiro | Perda potencial de zeros à esquerda | Cast para string e renomeação para cod_ibge | Preserva integridade de identificador e padroniza joins |
| Metadados: desc_mun, uf, populacao | Nomes curtos, ambíguos e genéricos | Renomeação para nome, uf_sigla e populacao_total | Nomes autoexplicativos sem necessidade de dicionário |
| ~360 colunas em string (textos livres e binários) | Impossível tratar colunas manualmente | Agregação única collect_set() para classificar binário/categórico | Automação e escalabilidade para novos censos |
| Colunas binárias em texto ("Sim"/"Não") | Ocupam mais memória e exigem filtro de string | Cast para tipo boolean (True/False/NULL) | Redução de armazenamento e operações lógicas nativas |
| Textos: "Recusa", "Não informou", "Não sabe", "-" | Tratar como texto polui contagens e métricas de qualidade | Conversão explícita para NULL | Tratamento nativo de dados faltantes em SQL |
| Strings com espaços extras (" Via cabo ") | Criação de falsas categorias em agrupamentos | Aplicação de F.trim() | Padronização e eliminação de falsa cardinalidade |
| Duas tabelas idênticas (MTIC e MGOV) | Duplicação de lógica (violação do princípio DRY) | Função única treat_survey_indicators parametrizada | Manutenibilidade centralizada e código reutilizável |
| Duas tabelas antes do inner join | Risco de duplicatas ou perda de municípios | Asserts de unicidade de PK e contagem (5.570 linhas) | Mecanismo fail-fast contra corrupção de dados |
| Bases isoladas (MTIC, MGOV e metadados) | Dificulta análises correlacionadas | Inner joins sequenciais por chave municipal | Dataset consolidado Silver pronto para consumo |
| Persistência final em Silver | Alterações estruturais e falta de linhagem | Gravação Delta com overwriteSchema e userMetadata | Evolução de schema e rastreabilidade via DESCRIBE HISTORY |

### 4.1 Registros descartados

Nenhum registro foi descartado

### 4.2 Rastreabilidade do pipeline

O pipeline está organizado em quatro camadas no Unity Catalog. A camada de *landing* recebe o arquivo original do IBGE com o nome versionado preservado. A camada *bronze* armazena os dados como vieram, acrescidos dos metadados de proveniência. A camada *silver* aplica as transformações da tabela acima. As evidências de qualidade são geradas sobre a camada *bronze* e gravadas em tabelas próprias. Cada notebook corresponde a uma transição entre camadas, e o histórico de versões de cada tabela Delta é consultável por DESCRIBE HISTORY, permitindo reproduzir a base tratada a partir do arquivo original.

| Camada / Ativo | Transição / Processamento | Destino & Governança | Regras & Transformações |
|---|---|---|---|
| 1. Landing<br>*(Storage)* | ➔ landing_to_bronze<br>*(Notebook)* | 2. Bronze<br>*(Delta Table)* | • Preserva nome original do arquivo IBGE (XLSX)<br>• Carga bruta sem perda de dados<br>• Injeção de metadados (ano_edicao) |
| 2. Bronze<br>*(Delta Table)* | ➔ bronze_data_quality<br>*(Notebook Paralelo)* | Tabelas de Qualidade<br>*(Delta Table)* | • Métricas de completude e integridade<br>• Rastreio de nulos e profiling de dados<br>• Auditoria sem impacto no pipeline principal |
| 3. Bronze<br>*(Delta Table)* | ➔ bronze_to_silver<br>*(Notebook Principal)* | Silver Consolidada<br>*(Delta Table)* | • Padronização para snake_case<br>• Cast cod_munic (int) ➔ cod_ibge (string)<br>• Indicadores binários (boolean)<br>• Códigos de não resposta ➔ NULL<br>• Inner Joins (MTIC + MGOV + Metadados) |

## 5. Privacidade e ética

Ainda que se trate de base pública e de unidade de análise institucional, a utilização dos dados foi avaliada quanto aos aspectos de privacidade, proteção de dados pessoais e potenciais vieses.

| Subseção | Aspecto avaliado | Diagnóstico / Achado |
|---|---|---|
| 5.1 Dados pessoais | Presença de atributos de pessoas físicas na base | Sem identificadores diretos (nome/CPF/contato); presença de vínculo e formação |
| 5.2 Reidentificação | Risco de vinculação indireta de atributos a indivíduos | Risco em municípios pequenos por combinação de cargo, vínculo e formação |
| 5.3 Dados sensíveis | Ocorrência de categorias protegidas (art. 5º, II, LGPD) | Nenhum dado sensível identificado nas abas analisadas |
| 5.4 Vieses | Distribuição não aleatória de não-resposta por porte | Municípios menores apresentam maior taxa de "Não sabe informar" |
| 5.5 Sub-representação | Concentração proporcional de municípios na amostragem | 87,88% dos municípios possuem até 50 mil hab.; grande porte = 0,86% |
| 5.6 Limitações | Condições de uso do índice e natureza das declarações | Dados autodeclarados sem auditoria; dependência forte do porte |

### 5.1 Existência de dados pessoais

A unidade de análise é institucional, mas há variáveis que descrevem pessoas físicas: Mgov15 registra o vínculo do responsável pelo controle interno e Mgov16 sua formação acadêmica. Não há nome, documento ou contato.

### 5.2 Possibilidade de reidentificação

Embora não haja identificadores diretos, a combinação de município, cargo, vínculo e formação pode identificar uma pessoa específica em municípios de pequeno porte, onde a estrutura administrativa é reduzida. O risco é de reidentificação por combinação de atributos, e não por identificação direta.

### 5.3 Dados sensíveis

Não foram identificadas categorias de dados sensíveis na acepção do art. 5º, II, da LGPD. As variáveis sobre pessoas limitam-se a vínculo funcional e formação acadêmica.

### 5.4 Possíveis vieses

A ausência de resposta não é aleatória. Conforme demonstrado na seção 3.8, 16,93% dos municípios de até 5 mil habitantes não souberam informar se possuem responsável pela LGPD, contra 2,08% entre os de mais de 500 mil. Como a ausência está correlacionada com a mesma capacidade institucional que o índice pretende medir, tratá-la como aleatória

produziria um resultado sistematicamente otimista justamente nos municípios de menor maturidade.

### 5.5 Grupos sub-representados

Os 48 municípios com mais de 500 mil habitantes representam 0,86% da base, enquanto as quatro faixas de até 50 mil habitantes concentram 87,88% dos registros. Procedimentos não supervisionados aplicados sobre a base tenderão a ser dominados pelo perfil dos municípios de pequeno porte.

### 5.6 Limitações de uso

O índice não deve ser utilizado para ranqueamento punitivo entre municípios, uma vez que a taxa de respostas afirmativas acompanha o porte populacional e reflete capacidade institucional tanto quanto maturidade em governança. Os dados são autodeclarados pelas prefeituras, sem auditoria independente, e descrevem a situação no período de coleta.

## 6. Produto da Etapa 2

- Dataset tratado: *munic_catalog.silver.munic_clean_data*, com 5570 registros, e *munic_catalog.silver.munic_clean_dict*.
- Dicionário de dados: seção 2 deste documento e arquivo *dicionario_esqueleto.csv*.
- Relatório de qualidade: seção 3 deste documento e tabelas *munic_catalog.gold.dq_**.
- Registro das transformações: seção 4 deste documento e notebook *bronze_to_silver*.

*Observação: os aspectos de segurança, governança de IA/Dados e monitoramento serão aprofundados nas etapas seguintes.*

## REFERÊNCIAS

INSTITUTO BRASILEIRO DE GEOGRAFIA E ESTATÍSTICA (IBGE). *Pesquisa de Informações Básicas Municipais: Perfil dos Municípios Brasileiros 2024*. Rio de Janeiro: IBGE, 2025.